


MÉTRICAS DE EVALUACIÓN EN APRENDIZAJE AUTOMÁTICO

APRENDIZAJE AUTOMÁTICO



Es el subapartado de la inteligencia artificial que se centra en el desarrollo de sistemas capaces de aprender y mejorar automáticamente a partir de la experiencia sin ser programados explícitamente. Estos sistemas analizan grandes volúmenes de datos para identificar patrones y tomar decisiones informadas.

¿POR QUÉ ES IMPORTANTE EVALUARLOS?

No todos los modelos son igualmente efectivos. Las métricas de evaluación nos ayudan a:

- Medir su precisión: ¿Qué tan bien predice resultados?
- Detectar errores: ¿Está confundiendo clases importantes?
- Optimizar su uso: ¿Es adecuado para problemas médicos, financieros o de marketing?




CONCEPTOS CLAVE

1. Matriz de Confusión:

Tabla que resume las predicciones de un modelo de clasificación comparándolas con los valores reales.

Componentes:

- **TP (Verdaderos Positivos):** Casos positivos correctamente identificados.
- **TN (Verdaderos Negativos):** Casos negativos correctamente identificados.
- **FP (Falsos Positivos):** Casos negativos incorrectamente clasificados como positivos.
- **FN (Falsos Negativos):** Casos positivos incorrectamente clasificados como negativos.



$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2. Accuracy (Exactitud)

Es la proporción de predicciones correctas sobre el total. No es muy confiable si hay desbalance en los datos.



3. Sensitivity/Recall (Sensibilidad/Exhaustividad)


Es la capacidad del modelo para detectar casos positivos. Importante en diagnósticos médicos o detección de fraudes (evitar FN).

$$Recall = \frac{TP}{TP + FN}$$

$$Specificity = \frac{TN}{TN + FP}$$

4. Specificity (Especificidad)

Capacidad de medir la proporción de instancias negativas que el modelo clasifica correctamente como negativas.



5. Precision (Precisión)

Es la proporción de verdaderos positivos (TP) entre todas las predicciones positivas realizadas por un modelo.

$$Precision = \frac{TP}{TP + FP}$$

$$F1 - Score = \frac{2 * Precision * Recall}{Precision + Recall}$$

6. F1-Score

Es la media armónica entre la precisión y la exhaustividad (recall), proporcionando un equilibrio entre ambas métricas. Es especialmente útil cuando las clases están desbalanceadas.



RECOMENDACIONES FINALES

Selecciona la métrica adecuada según el objetivo:

Priorizar la detección de casos positivos:

Usar Recall (Sensibilidad) para minimizar falsos negativos.

Reducir falsas alarmas y optimizar precisión:

Usar Precisión para minimizar falsos positivos.

Balancear precisión y recall:

Usar F1-Score como métrica intermedia.

Cuando las clases están bien distribuidas

Usar Accuracy para medir el desempeño general.

Para identificar correctamente los casos negativos:

Usar Especificidad para minimizar falsos positivos.

Consejos clave:

- ✓ Analizar la matriz de confusión para visualizar errores.
- ✓ Priorizar Recall o F1-Score en datos desbalanceados.
- ✓ Evaluar el costo de cada tipo de error antes de decidir.

[1] S. Raschka, V. Mirjalili, Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2, 3rd ed. Birmingham, UK: Packt, 2019.
[2] T. Hastie, R. Tibshirani, and J. Friedman, The Elements of Statistical Learning: Data Mining, Inference, and Prediction, 2nd ed. New York, NY, USA: Springer, 2009.
[3] C. M. Bishop, Pattern Recognition and Machine Learning, New York, NY, USA: Springer, 2006.
[4] J. Han, M. Kamber, and J. Pei, Data Mining: Concepts and Techniques, 3rd ed. Amsterdam, Netherlands: Elsevier, 2011.
[5] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 2nd ed. Sebastopol, CA, USA: O'Reilly Media, 2019.

[6] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," J. Mach. Learn. Res., vol. 12, pp. 2825–2830, 2011.
[7] D. Powers, "Evaluation: From precision, recall and F-measure to ROC, informedness, markedness & correlation," J. Mach. Learn. Technol., vol. 2, no. 1, pp. 37–63, 2011.
[8] A. Ng, "Machine Learning Yearning," 2018. [Online]. Available: <https://www.mlyearning.org/>, [Accessed: 09-Feb-2025].
[9] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," Nature, vol. 521, no. 7553, pp. 436–444, 2015.
[10] K. Murphy, Machine Learning: A Probabilistic Perspective, Cambridge, MA, USA: MIT Press, 2012.